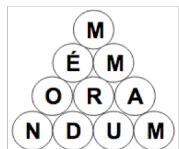




## Dojo Tensorflow #1

Chez Sfeir



# Le **développeur** au coeur du **digital**



 @sfeir

Marre de stagner? Envie de vous tester sur de nouveaux challenges techniques? Venez passer les Playoffs!

#SFEIRCode

<https://t.co/7xJBzlwRwY>

09:05 - 14 Mar 2016 

 @sfeir

Félicitations @cbalit !!!  
Nouveau #gde chez les Sfeiriens !

<https://t.co/h6moPbLMIm>

14:47 - 11 Mar 2016 

# Mémorandum

Mémorandum est un cabinet de **conseil en data stratégie**.

Nous intervenons en trois phases :

1. Réflexion sur l'usage de la donnée dans votre entreprise
2. Analyse de vos données
3. Industrialisation de solutions informatiques

Nous apportons :

- Une méthodologie mélant stratégie et technique.
- Des preuves de concepts “machine learning” avec les outils en pointe de la communauté open source
- Des méthodes agiles et de Lean Analytics qui garantissent des résultats adaptés



**Romain Jouin - Associé**

INT Management 2006 - Télécom Paris 2013  
7 ans de commercial  
25 ans d'informatique

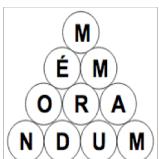


**Denis Oblin - Associé**

Centrale 1994 - Télécom Paris 2013  
10 ans de conseil en stratégie  
7 ans en direction opérationnelle Groupama

## Mémorandum a trois expertises majeures :

- Technique
  - ◆ Big Data
  - ◆ Machine Learning
- Fonctionnelle
  - ◆ Stratégie de la micro décision
  - ◆ Marketing
- Métier
  - ◆ Relation client
  - ◆ Force de vente



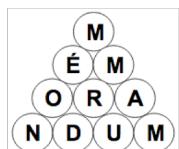
 Installation

Lesson 1

Lesson 2 (to do)

Lesson 3 (to do)

Lesson 4 (to do)





## Deep Learning

Take machine learning to the next level



Advanced



Approx. 3 months

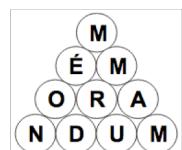
Assumes 6hrs/wk (work  
at your own pace)



Join 61,607 students

Built by

Google



## ▼ Prerequisites and Requirements

This is an intermediate to advanced level course. Prior to taking this course, and in addition to the prerequisites and requirements outlined for the Machine Learning Engineer Nanodegree program, you should possess the following experience and skills:

- Minimum 2 years of programming experience (preferably in Python)
- Git and GitHub experience (assignment code is in a GitHub repo)
- Basic machine learning knowledge (especially supervised learning)
- Basic statistics knowledge (mean, variance, standard deviation, etc.)
- Linear algebra (vectors, matrices, etc.)
- Calculus (differentiation, integration, partial derivatives, etc.)

scipy, numpy, scikit learn...

## ▼ Syllabus

### **Lesson 1: From Machine Learning to Deep Learning**

- Understand the historical context and motivation for Deep Learning.
- Set up a basic supervised classification task and train a black box classifier on it.
- Train a logistic classifier "by hand" Optimize a logistic classifier using gradient descent, SGD, Momentum and AdaGrad.

### **Lesson 2: Deep Neural Networks**

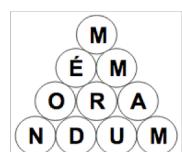
- Train a simple deep network.
- Effectively regularize a simple deep network.
- Train a competitive deep network via model exploration and hyperparameter tuning.

### **Lesson 3: Convolutional Neural Networks**

- Train a simple convolutional neural net.
- Explore the design space for convolutional nets.

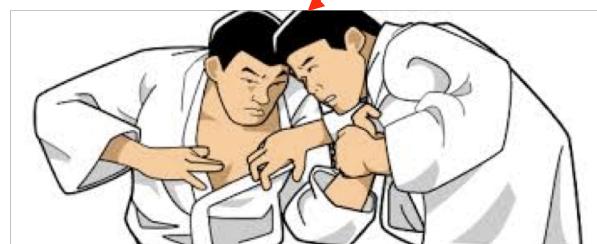
### **Lesson 4: Deep Models for Text and Sequences**

- Train a text embedding model.
- Train a LSTM model.

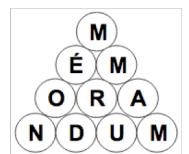
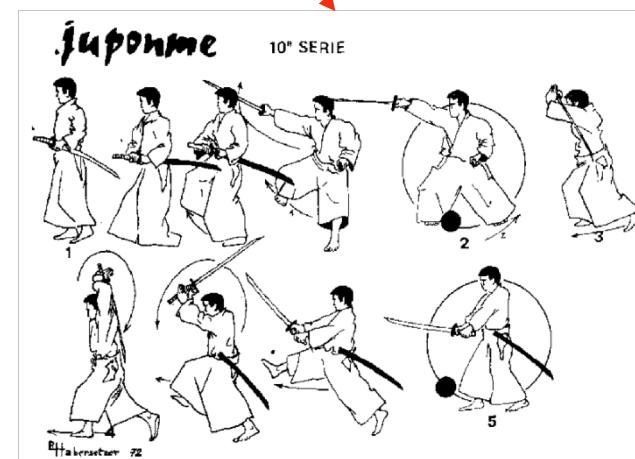




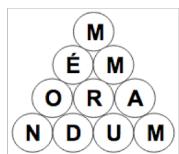
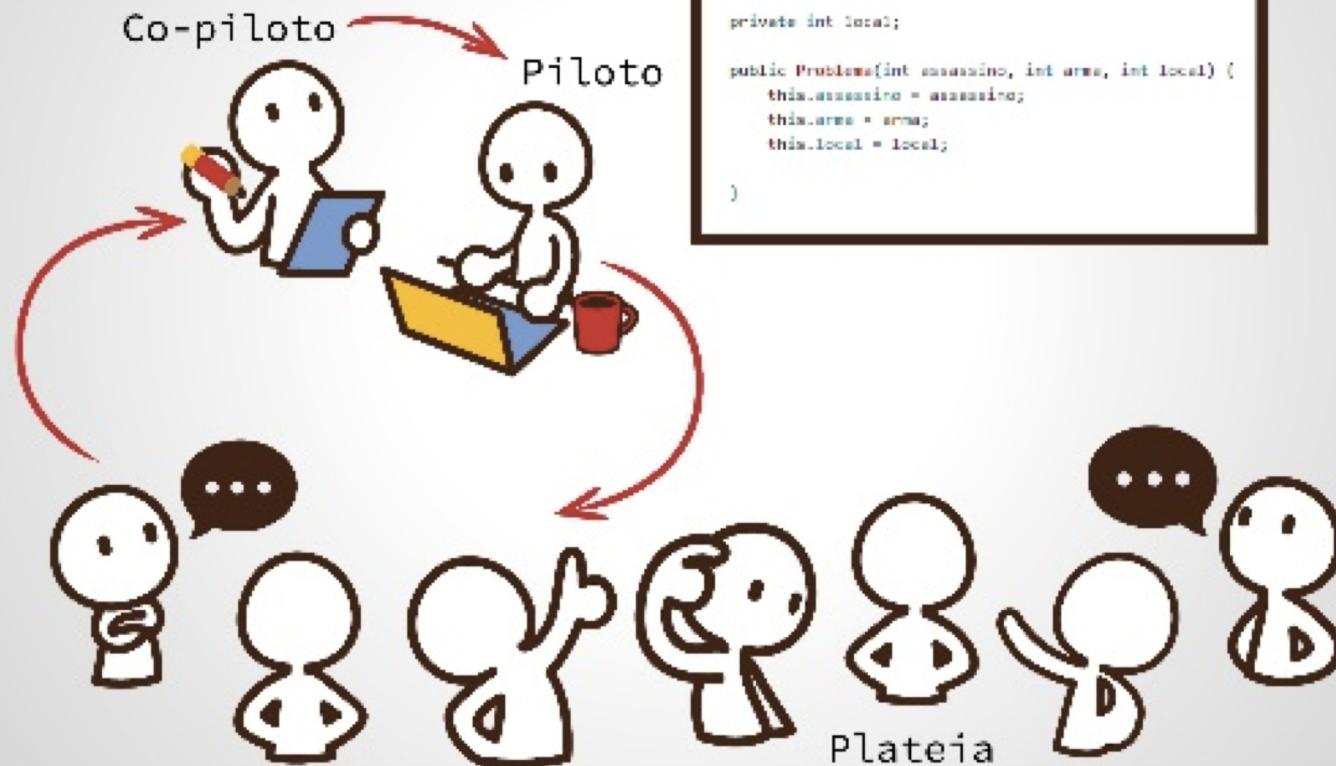
Randori



Kata

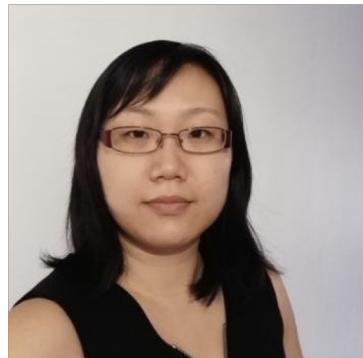


# Dojo Randori



Ce soir 4 intervenants

# Alphabet



Donne le cours udacity  
<https://www.udacity.com/course/deep-learning--ud730>

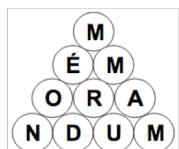
Expertise Tensorflow



Nous expliquera les matsh



Animera la soirée



Docker propose un docker file pour lancer  
l'environnement

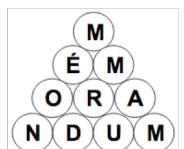
**docker run -p 8888:8888 -it --rm b.gcr.io/tensorflow-udacity/assignments:0.4.0**

<https://github.com/tensorflow/tensorflow/blob/master/tensorflow/examples/udacity/README.md>



## Ou bien nous avons notre propre dockerfile

```
FROM b.gcr.io/tensorflow/tensorflow
RUN apt-get update
RUN apt-get install -y gfortran python-pip python-dev git mc vim
RUN apt-get install -y python-numpy python-scipy libatlas-base-dev
RUN pip install --upgrade pip
RUN pip install -U pandas
RUN easy_install scipy
RUN pip install --upgrade scipy
RUN pip install -U scikit-learn
RUN pip install git+git://github.com/tensorflow/skflow.git
RUN pip install --upgrade --user ipython
RUN mkdir /notebook
VOLUME /notebook
EXPOSE 8888 6006
CMD jupyter notebook /notebook
```



Environnement pour la soirée

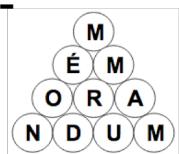


# THE MNIST DATABASE of handwritten digits

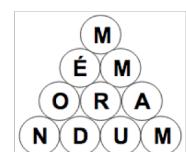
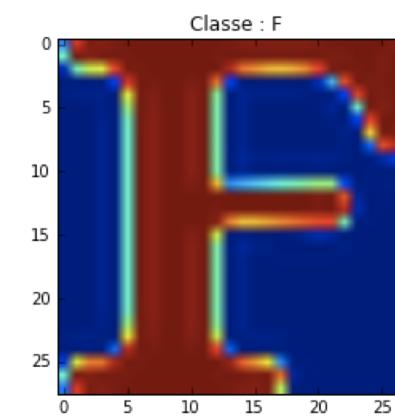
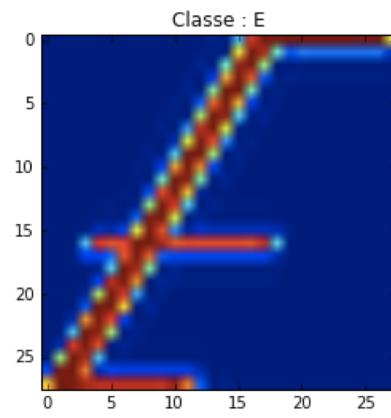
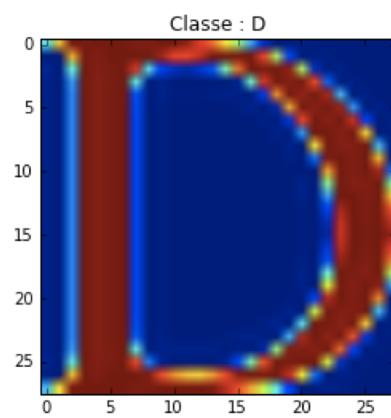
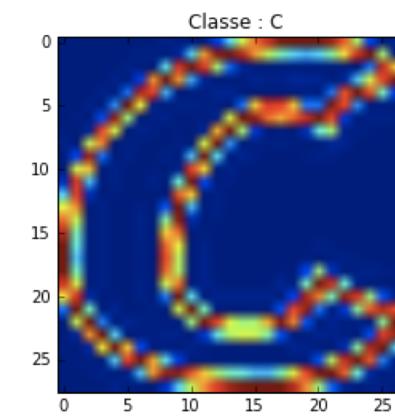
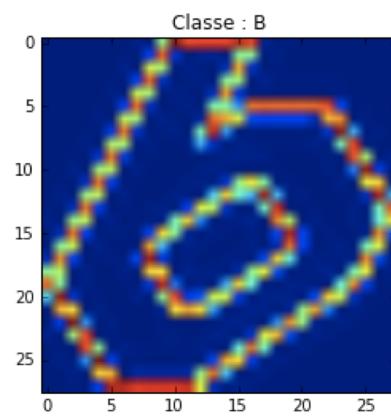
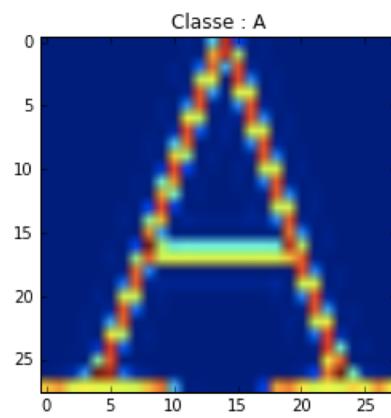
[Yann LeCun](#), Courant Institute, NYU  
[Corinna Cortes](#), Google Labs, New York  
[Christopher J.C. Burges](#), Microsoft Research, Redmond

The MNIST database of handwritten digits, available from this page, has a training set of 60,000 examples, and a test set of 10,000 examples. It is a subset of a larger set available from NIST. The digits have been size-normalized and centered in a fixed-size image.

<http://yann.lecun.com/exdb/mnist/>



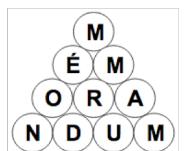
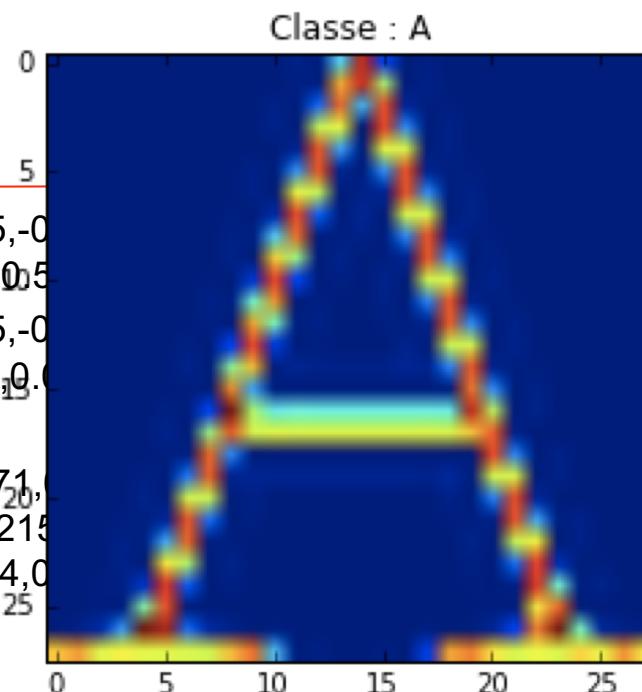
## MNIST Database



```
dataset.shape = (52909, 28, 28)
```

```
dataset[0].shape = (28, 28)
```

array(



## Installation

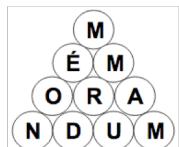


Lesson 1 – classification logistique et descente de gradient

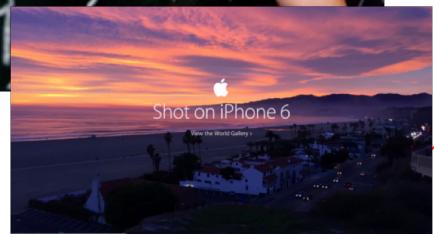
Lesson 2 - Réseau de neurone profond (to do)

Lesson 3 - Réseau de convolution (to do)

Lesson 4 – Réseau de neurone profond pour l'analyse de texte et de séquences (to do)



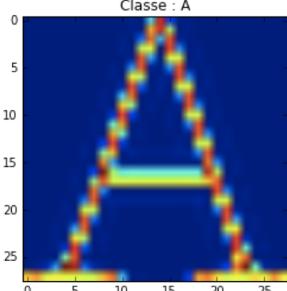
$$\frac{3}{39} \left[ a_1(y+1)^2 + a_2(y+1) + a_3(y+1)^3 + a_4(y+1)^4 \right]$$



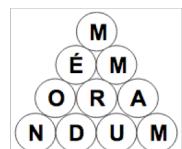
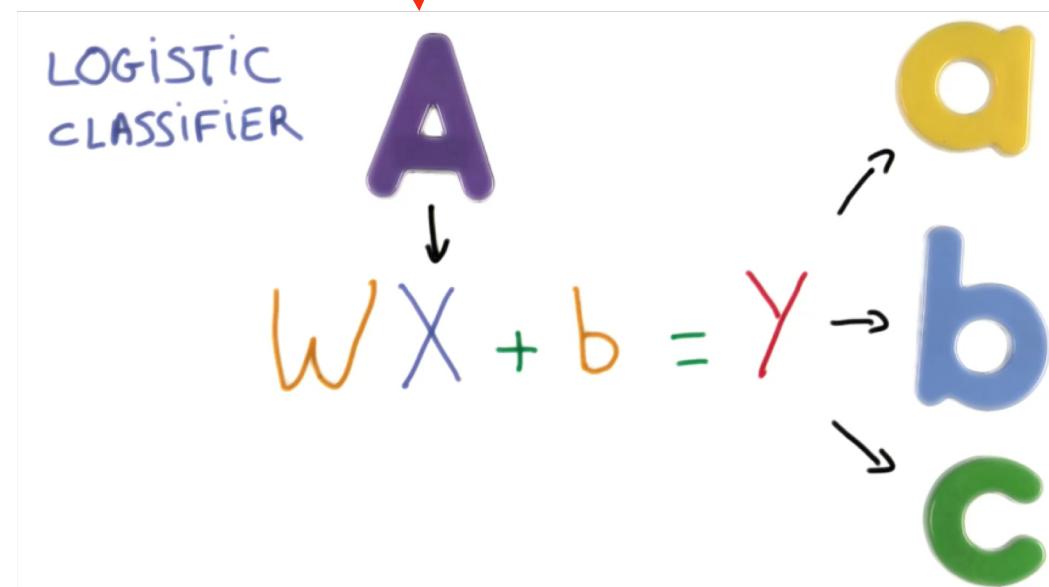
12 millions de paramètres



## Logistic classifier et softmax



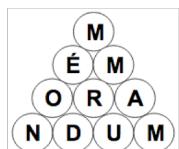
$$28 * 28 = 756$$





# randori #1

- Objectif : implémenter la fonction softmax
- Durée prévue : 10 minutes max
- Nombre de codeurs : 1 à 2
- Nombre de lignes dans la réponse : 1 fonction de 3 lignes



## Practical issues of softmax: Numeric stability

$$\frac{e^{f_{y_i}}}{\sum_j e^{f_j}} = \frac{Ce^{f_{y_i}}}{C \sum_j e^{f_j}} = \frac{e^{f_{y_i} + \log C}}{\sum_j e^{f_j + \log C}}$$

$$\log C = - \max_j f_j$$

We are free to choose the value of  $C$ .

## Practical issues: Numeric stability

```
f = np.array([123, 456, 789]) # example with 3 classes and each having large scores
p = np.exp(f) / np.sum(np.exp(f)) # Bad: Numeric problem, potential blowup

# instead: first shift the values of f so that the highest number is 0:
f -= np.max(f) # f becomes [-666, -333, 0]
p = np.exp(f) / np.sum(np.exp(f)) # safe to do, gives the correct answer
```

$$\frac{3a(y+z)^2}{39} + \frac{3y}{39} + \frac{4z}{39}$$

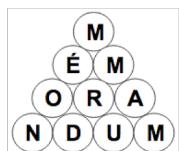
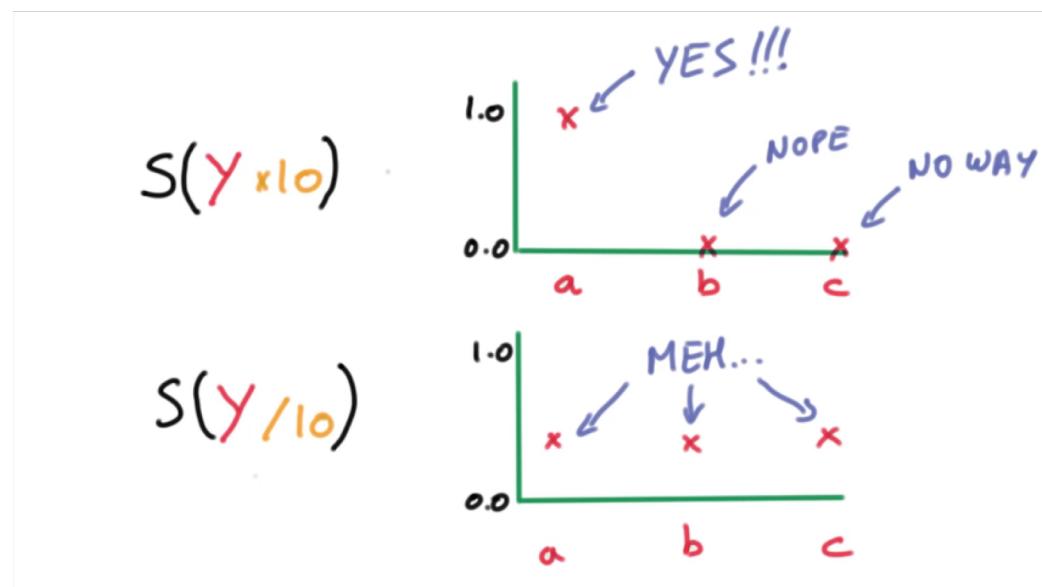
## One hot encoding

Pour prendre une décision binaire sur la classification, on peut transformer les probabilités en valeurs "0" ou "1". C'est le "One hot encoding".

Il faut alors un vecteur par classe, qui contiendra plein de zéros, et une seule valeur "1".

Ainsi chaque classe a son vecteur signature qui lui permet d'être reconnaissable.

Le problème du one-hot encoding c'est que ça créé des matrices très "creuses" s'il y a beaucoup de classes : on a quasiment que des zéros, pour un seul "1" par colonne.



$$\begin{aligned}
 & 3a(y+1)^2 + (3y+4A(x+ \\
 & \frac{a^2(3)}{39} (y+A)^2 + \frac{2}{3}(x+A)^2
 \end{aligned}$$

## Cross entropy

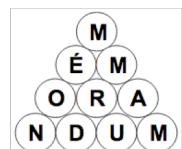
Cette fonction permet de transformer l'ensemble des probabilités en un vecteur binaire avec un seul "1", qui sera la classe élue.

On a donc :

input => modèle => score => softmax  
=>probabilité => cross-entropy => classe choisie.

C'est la classification logistique multinomiale.

$a \rightarrow$	0	0	0	0	0	0
$b \rightarrow$	0	0	0	0	0	0
$c \rightarrow$	0	0	0	0	0	0
$d \rightarrow$	0	0	0	0	0	0
$\vdots$	0	0	0	0	0	0
.	0	0	0	0	0	0
0	0	0	0	0	0	0





## Schotastic gradient descent

Comment trouver la matrice des poids [W] et la matrice de biais [b] qui nous permettent d'atteindre notre objectif, à savoir :

- 1) d'avoir une petite distance aux classes correctes
- 2) d'avoir une grande distances aux classes incorrectes

En apprentissage supervisé on peut calculer la distance entre notre classification logistique (multinomiale) et les classes connues. La différence est l'erreur, appelée en anglais "loss".

On définit donc une fonction de mesure de l'erreur ; la "loss function", que l'on définit selon les cas comme l'on veut.

Par exemple ici on peut la définir comme étant une moyenne des erreurs de distance :

loss = sum ( cross\_entropy ( classification logistique, valeur réelle)) / nombre\_de\_lignes\_connues

loss = 1/n \* SUM[i]( D( S( W\*Xi + b), Li ) )

=> W est la matrice des poids

=> Xi est une ligne connue, avec Li la réponse connue (le label / la classe)

=> D est la fonction de cross-entropy qui va convertir les score en proba

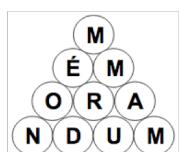
C'est à dire que la loss function ici est la moyenne des erreurs.

Pour réduire la cross entropy on va essayer de changer W de manière à réduire la fonction de perte. Comment faire ? on essaie en changeant les valeurs dans W ;)

Mais il y a des manières intelligentes de changer W : on peut utiliser la méthode de la "descente de gradient".

La descente de gradient fonctionne un peu comme quelqu'un sur une colline qui voudrait descendre en bas : il pose son pied à plusieurs endroits et avance là où il sent que la colline descend.

En termes plus mathématiques, on calcule la dérivée de la fonction de perte en accord avec les paramètres, et on avance d'un pas dans cette direction.

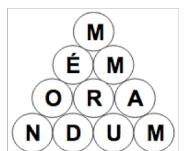
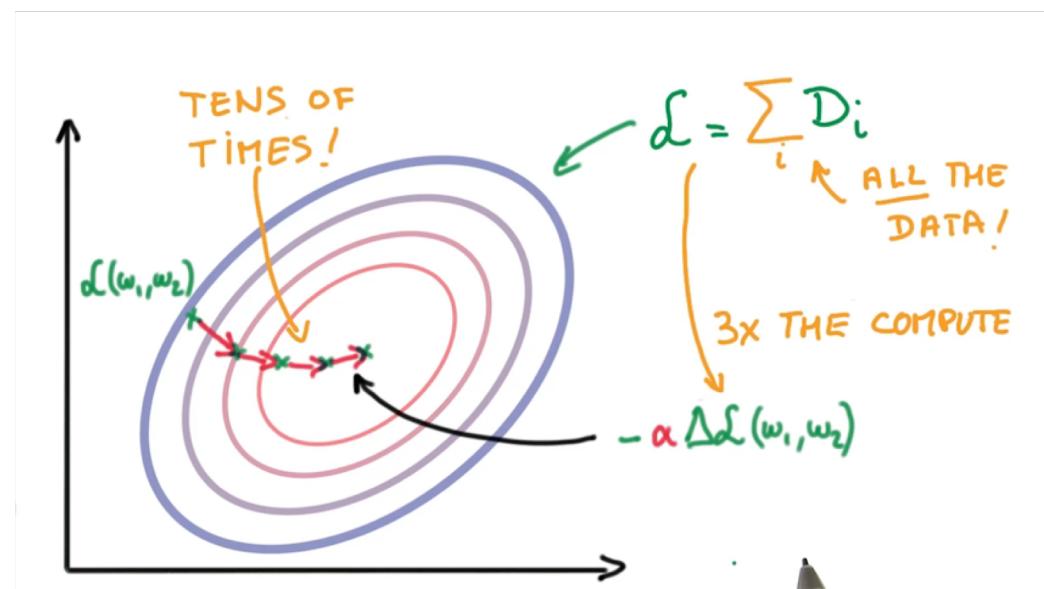


$$\frac{\partial}{\partial w} \left[ \frac{1}{2} \sum_{i=1}^n (y_i + A)^2 \right] = \frac{1}{2} \sum_{i=1}^n 2(y_i + A) = \sum_{i=1}^n (y_i + A)$$

## Schotastic gradient descent (vidéo 36)

Comment trouver la matrice des poids [W] et la matrice de biais [b] qui nous permettent d'atteindre notre objectif, à savoir :

- 1) d'avoir une petite distance aux classes correctes
- 2) d'avoir une grande distances aux classes incorrectes



## Jeu de donnée utilisé pendant le MOOC



Chaque répertoire contient environ 50 000 images

Téléchargement  
10 classes : A -> J

training set : 500k images  
**train\_datasets**

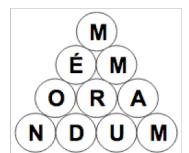
Test set : 19k images  
**test\_datasets**

```
[ 'notMNIST_small/A.pickle',
  'notMNIST_small/B.pickle',
  'notMNIST_small/C.pickle',
  'notMNIST_small/D.pickle',
  'notMNIST_small/E.pickle',
  'notMNIST_small/F.pickle',
  'notMNIST_small/G.pickle',
  'notMNIST_small/H.pickle',
  'notMNIST_small/I.pickle',
  'notMNIST_small/J.pickle']
```



notMNIST\_large/A.pickle  
notMNIST\_large/B.pickle  
notMNIST\_large/C.pickle  
notMNIST\_large/D.pickle  
notMNIST\_large/E.pickle  
notMNIST\_large/F.pickle  
notMNIST\_large/G.pickle  
notMNIST\_large/H.pickle  
notMNIST\_large/I.pickle  
notMNIST\_large/J.pickle

notMNIST\_small/A.pickle  
notMNIST\_small/B.pickle  
notMNIST\_small/C.pickle  
notMNIST\_small/D.pickle  
notMNIST\_small/E.pickle  
notMNIST\_small/F.pickle  
notMNIST\_small/G.pickle  
notMNIST\_small/H.pickle  
notMNIST\_small/I.pickle  
notMNIST\_small/J.pickle



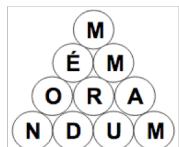
## Installation

Lesson 1 – classification logistique et descente de gradient

► Lesson 2 - Réseau de neurone profond (to do)

Lesson 3 - Réseau de convolution (to do)

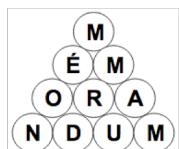
Lesson 4 – Réseau de neurone profond pour l'analyse de texte et de séquences (to do)





# randori #2

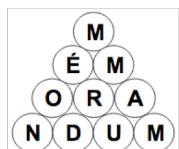
- Objectif : afficher trois images de chaque classe
- Durée prévue : 7 minutes, 10 minutes maximum
- Nombre de codeurs : 1 à 2
- Nombre de lignes dans la réponse : 8





# randori #3

- Objectif : vérifier que les 10 classes sont « balancées »
- Durée prévue : 5 minutes, 10 minutes maximum
- Nombre de codeurs : 1 à 2
- Nombre de lignes dans la réponse : 5

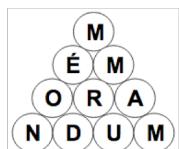




# randori #4

- Objectif : vérifier que les 10 classes sont « balancées » après shuffling
- Durée prévue : 5 minutes, 10 minutes maximum
- Nombre de codeurs : 1 à 2
- Nombre de lignes dans la réponse : 5

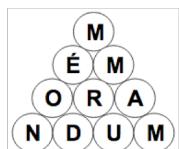
**SKIP**





# randori #5

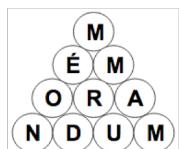
- Objectif : trouver les images dupliquées entre les jeux de données
- Durée prévue : 20 minutes à 30 minutes maximum
- Nombre de codeurs : 4 à 6
- Nombre de lignes dans la réponse : une quinzaine
  
- Options :
  - Quid des images « presques dupliquées » ?
  - Créer des datasets sans duplication





# randori #6

- Objectif :
  - créer un classifieur avec scikit learn pour une régression logistique
  - tester sur des sous ensemble de 50 / 100 / 1000 / 5000
  - calculer le temps d'exécution
- Durée prévue : 10 minutes, 15 minutes maximum
- Nombre de codeurs : 2 à 3
- Nombre de lignes dans la réponse : 5

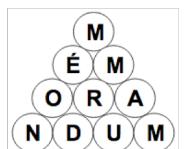
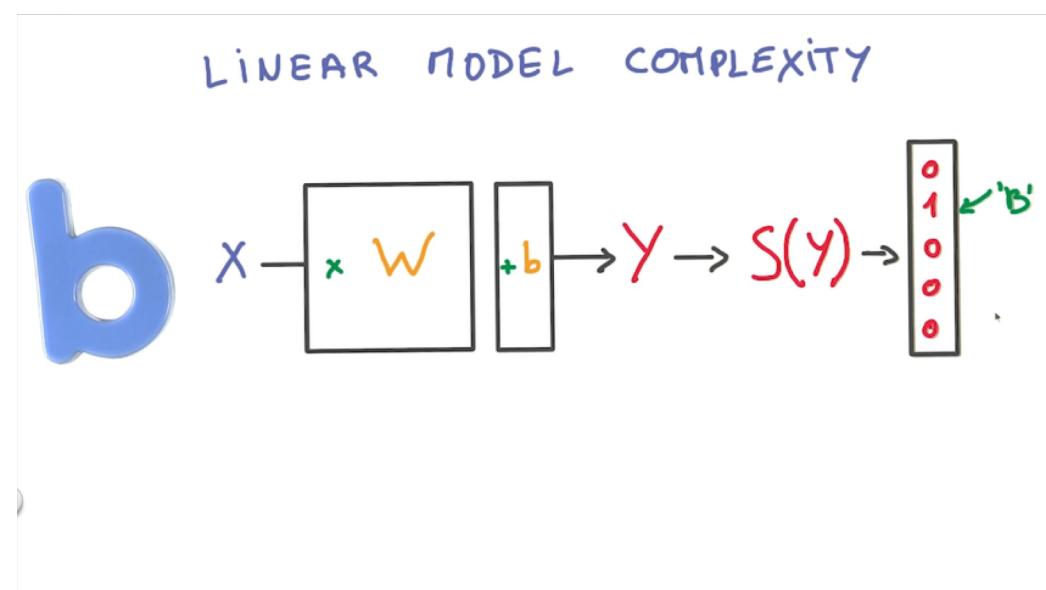


$$3a(y+z)^2 + (3y+4z+4A(x+z))^2 + 2\frac{(y+A)^3}{3} + \frac{2}{3}(x+z)^3$$

39

## Nombre de paramètres (vidéo 2)

Les fonctions linéaires sont très stables, et se calculent bien sur GPU. On voudrait donc les conserver. Par contre elles ne permettent pas de faire tout type de calculs. Donc on va chercher à les modifier pour étendre le champ des possibles.



## RELU (vidéo 5)

Le « relu » est une fonction très simple : c'est le maximum entre 0 et  $x$  ....

Rappel - dérivée :

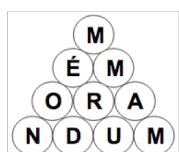
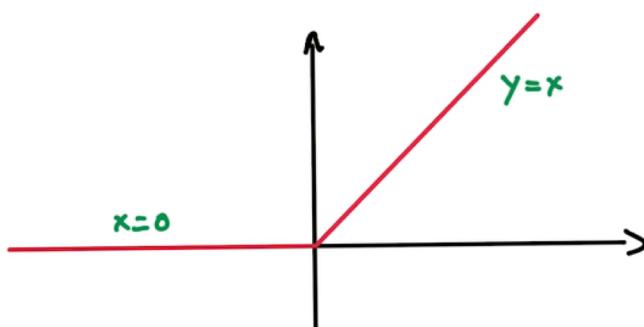
Définition formelle [\[ modifier \]](#) [\[ modifier le code \]](#)

Soit  $f$  une [fonction réelle](#) à valeurs réelles définie sur une réunion quelconque d'[intervalles](#) non triviaux, et  $x_0$  appartenant à l'intérieur de l'ensemble de définition  $\mathcal{D}_f$ .

Pour tout  $h \in \mathbb{R}^*$  tel que  $[x_0, x_0 + h] \subset \mathcal{D}_f$ , on appelle *taux d'accroissement de  $f$  en  $x_0$*  et avec un pas de  $h$  la quantité :

$$t_{x_0}(h) = \frac{f(x_0 + h) - f(x_0)}{h}$$

RECTIFIED LINEAR UNITS (RELU)



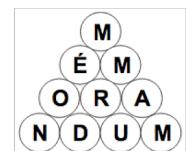
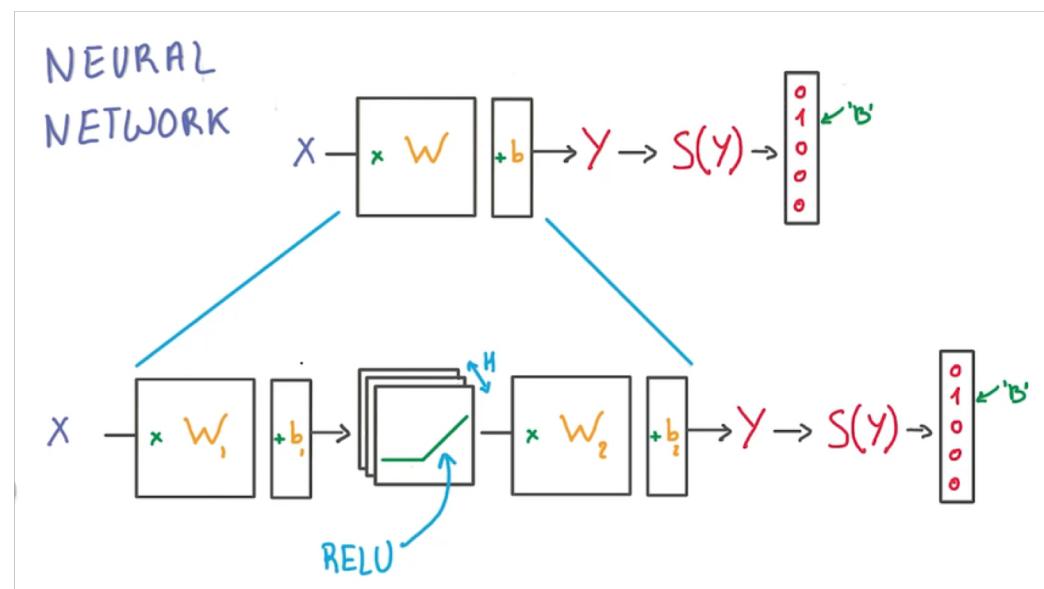
## Réseau de neurone profond (vidéo 7)

On rend les fonctions non linéaires en insérant une fonction « relu » au milieu de la fonction...

Les calculs des dérivées restent alors très simple :

$$[g(f(x))]' = g'(f(x)) * f'(x)$$

Comme la descente de gradient fait principalement du calcul de dérivée, il est important que cela reste simple.



$$\frac{\partial}{\partial w} \left[ \frac{1}{2} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \frac{1}{2} \sum_{i=1}^m (z_i - \hat{z}_i)^2 + \frac{1}{2} \sum_{j=1}^k (A_j - \hat{A}_j)^2 \right]$$

## Back Propagation

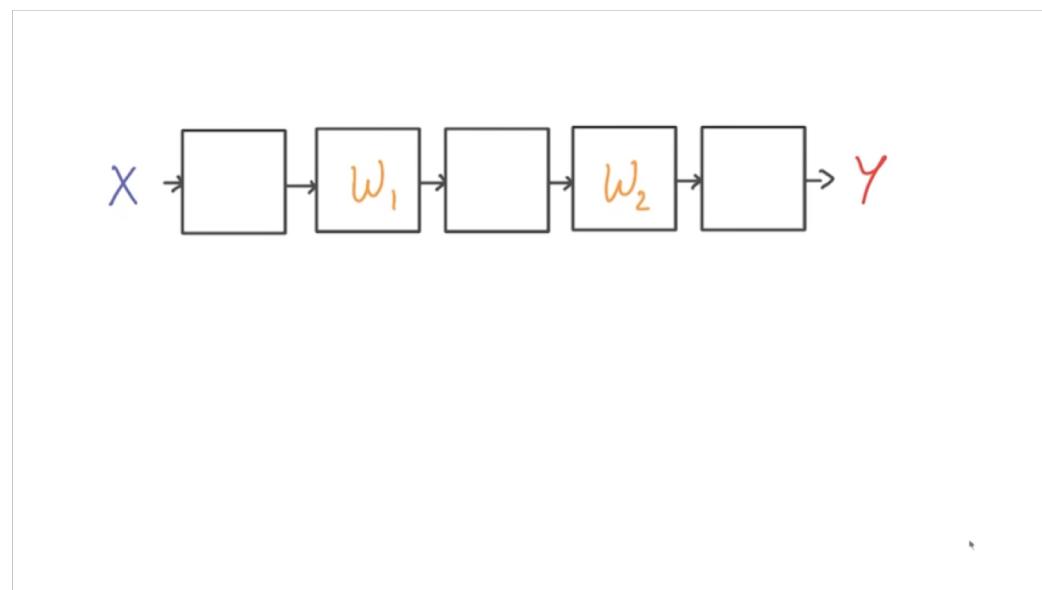
Le calcul du gradient pour un ensemble de poids  $\mathbf{W}$  donné se fait en deux étapes :

### 1) Forward propagation

1) relu -> transformation linéaire -> relu -> transformation linéaire

1) On obtient alors une première prédiction  $Y$

2) Pour affiner cette prédiction et faire la descente de gradient, il faut trouver les dérivées. Pour trouver les dérivées, on va passer par l'étape 2

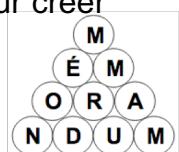


### 2) Back propagation

Le graph de back-propagation est calculé par Tensorflow (il est déduit du premier graph), on n'a donc pas en le programmer.

Il calcule des dérivées pour de la matrice de poids  $\mathbf{W}$  que l'on va soustraire de  $\mathbf{W}$  pour créer une nouvelle matrice qui la remplacera.

3) on applique un coefficient alpha sur la dérivée de  $\mathbf{W}$  avant la soustraction





[https://www.tensorflow.org/versions/r0.7/api\\_docs/python/state\\_ops.html#variables](https://www.tensorflow.org/versions/r0.7/api_docs/python/state_ops.html#variables)

Building Graphs:	26
Constants, Sequences, and Random Values:	14
Variables:	32
Tensor Transformations:	31
Math:	80
Control Flow:	26
Images:	35
Sparse Tensors:	11
Inputs and Readers:	30
Data IO (Python functions):	2
Neural Network:	34
Running Graphs:	20
Training:	35
Wraps python functions:	1
Testing:	6
Layers (contrib):	12
Utilities (contrib):	2

```
#Program that makes up some data in two dimensions, and then fits a line to it.

import tensorflow      as tf
import numpy           as np

# Create 100 phony x, y data points in NumPy, y = x * 0.1 + 0.3
x_data = np.random.rand(100).astype(np.float32)
y_data = x_data * 0.1 + 0.3

# Try to find values for W and b that compute y_data = W * x_data + b
W = tf.Variable(tf.random_uniform([1], -1.0, 1.0))
b = tf.Variable(tf.zeros([1]))
y = W * x_data + b

loss    = tf.reduce_mean(tf.square(y - y_data)) # Minimize the mean squared
errors.
optimizer = tf.train.GradientDescentOptimizer(0.5)
train    = optimizer.minimize(loss)

init    = tf.initialize_all_variables()     # Before starting, initialize the variables
sess    = tf.Session()                      # Launch the graph.
sess.run(init)

for step in xrange(201):                   # Fit the line.
    sess.run(train)
    if step % 20 == 0: print(step, sess.run(W), sess.run(b))

# Learns best fit is W: [0.1], b: [0.3]
```



## Librairie 0.7 (1/4)

### Building Graphs

```
add_to_collection           as_dtype      bytes        control_dependencies    convert_to_tensor
convert_to_tensor_or_indexed_slices device       Dimension   Dtype        get_collection
get_seed      Graph        GraphKeys    import_graph_def     load_op_library
Operation    register_tensor_conversion_function RegisterGradient RegisterShape
Tensor       TensorShape
```

### Constants, Sequences, and Random Values

```
constant      fill          linspace      ones         ones_like
random_uniform range
```

```
set_random_seed
```

```
random_crop random_normal
truncated_normal
```

```
zeros
random_shuffle
zeros_like
```

### Variables

```
all_variables assert_variables_initialized assign      assign_add assign_sub constant_initializer
count_up_to device
get_checkpoint_state      get_variable get_variable_scope IndexedSlices
initialize_all_variables
initialize_variables latest_checkpoint make_template moving_average_variables
random_normal_initializer random_uniform_initializer Saver
scatter_add scatter_sub scatter_update
sparse_mask trainable_variables truncated_normal_initializer
```

### Tensor Transformations

```
boolean_mask      cast          concat      depth_to_space
expand_dims gather pack          pad         rank        reshape
shape_n          size          slice       space_to_depth
to_bfloat16      to_double    to_float
```

```
dynamic_partition      dynamic_stitch
reverse      reverse_sequence
squeeze      string_to_number
tile
```

## Librairie 0.7 (2/4)

### Math

abs accumulate\_n add add\_n argmax argmin batch\_cholesky  
batch\_matmul batch\_matrix\_determinant batch\_matrix\_inverse batch\_matrix\_solve batch\_matrix\_solve\_ls  
batch\_matrix\_triangular\_solve batch\_self\_adjoint\_eig ceil  
cos cross diag div edit\_distance erf erfc  
cholesky complex complex\_abs conj

### Control Flow

add\_check\_numerics\_ops Assert check\_numerics cond count\_up\_to equal greater  
greater\_equal group identity is\_finite is\_inf is\_nan less less\_equal  
logical\_and logical\_not logical\_or logical\_xor no\_op not\_equal Print select tuple  
verify\_tensor\_all\_finite where

### Images

adjust\_brightness adjust\_contrast adjust\_hue adjust\_saturation convert\_image\_dtype  
crop\_to\_bounding\_box decode\_jpeg decode\_png draw\_bounding\_boxes encode\_jpeg encode\_png extract\_glimpse  
flip\_left\_right flip\_up\_down grayscale\_to\_rgb hsv\_to\_rgb pad\_to\_bounding\_box per\_image\_whitening  
random\_brightness random\_contrast random\_flip\_left\_right random\_flip\_up\_down random\_hue  
random\_saturation resize\_area resize\_bicubic

### Sparse Tensors

shape sparse\_concat sparse\_fill\_empty\_rows sparse\_reorder sparse\_retain  
sparse\_split sparse\_tensor\_to\_dense sparse\_to\_dense sparse\_to\_indicator SparseTensor  
SparseTensorValue



## Librairie 0.7 (3/4)

### Inputs and Readers

```
batch           batch_join    decode_csv  decode_json_example   decode_raw    FIFOQueue  FixedLenFeature
FixedLengthRecordReaderFixedLenSequenceFeature           IdentityReader
matching_files          parse_example  parse_single_example  placeholder  QueueBase   RandomShuffleQueue
range_input_producer     read_file      ReaderBase   shuffle_batch  shuffle_batch_join
string_input_producer
```

### Data IO (Python functions)

```
tf_record_iterator    TFRecordWriter
```

### Neural Network

```
avg_pool        bias_add      compute_accidental_hits conv2d       conv2d_transpose      depthwise_conv2d      dropout
elu            embedding_lookup fixed_unigram_candidate_sampler in_top_k    l2_loss      l2_normalize
learned_unigram_candidate_sampler local_response_normalization log_uniform_candidate_sampler max_pool
max_pool_with_argmax    moments      nce_loss        relu         relu6        sampled_softmax_loss separable_conv2d
sigmoid        sigmoid_cross_entropy_with_logits
```

### Running Graphs

```
AbortedError AlreadyExistsError      CancelledError      DataLossError      DeadlineExceededError
FailedPreconditionError  get_default_session  InteractiveSession  InternalError  InvalidArgumentError
NotFoundError          OpError          OutOfRangeError    PermissionDeniedError ResourceExhaustedError Session
UnauthenticatedError    UnavailableError    UnimplementedError UnknownError
```



## Librairie 0.7 (4/4)

### Training

AdagradOptimizer	AdamOptimizer	add_queue_runner	AggregationMethod	clip_by_average_norm
clip_by_global_norm	clip_by_norm	clip_by_value	Coordinator	exponential_decay
ExponentialMovingAverage		export_meta_graph	FtrlOptimizer	generate_checkpoint_state_proto
global_norm	global_step	GradientDescentOptimizer	gradients	histogram_summary
import_meta_graph		LooperThread	merge_all_summaries	image_summary
Optimizer			merge_summary	MomentumOptimizer

### Wraps python functions

py\_func

### Testing

assert_equal_graph_def	compute_gradient	compute_gradient_error	get_temp_dir	is_built_with_cuda	main
------------------------	------------------	------------------------	--------------	--------------------	------

### Layers (contrib)

assert_same_float_dtype	convolution2d	fully_connected	l1_regularizer	l2_regularizer
summarize_activation	summarize_activations	summarize_collection	summarize_tensor	summarize_tensors
xavier_initializer	xavier_initializer_conv2d			

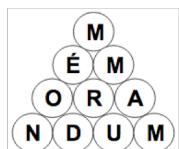
### Utilities (contrib)

constant_value	make_tensor_proto
----------------	-------------------



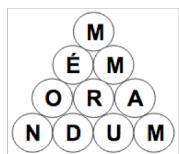
# randori # 7

- Objectfs : Reformat into a shape that's more adapted to the models we're going to train:
  - data as a flat matrix,
  - labels as float 1-hot encodings.





randori



## Practical issues of cross entropy:

### Tensorflow NaN bug? - Stack Overflow

[stackoverflow.com/questions/33712178/tensorflow-nan-bug](http://stackoverflow.com/questions/33712178/tensorflow-nan-bug) ▾ Traduire cette page

14 nov. 2015 - I'm using TensorFlow and I modified the tutorial example to take my RGB ...  
`cross_entropy = -tf.reduce_sum(y_*tf.log(tf.clip_by_value(y_conv ...`

### python - Why does TensorFlow return [[nan nan]] instead of ...

[stackoverflow.com/questions/33712178/tensorflow-nan-bug](http://stackoverflow.com/questions/33712178/tensorflow-nan-bug) ▾ Traduire cette page

25 nov. 2015 - Why does TensorFlow return [[nan nan]] instead of probabilities from a CSV file? ..... + 1e-50)) ## avoid nan due to 0\*log(0)  
`cross_entropy = tf.`

### python - Why does TensorFlow example fail when ...

[stackoverflow.com/questions/33712178/tensorflow-nan-bug](http://stackoverflow.com/questions/33712178/tensorflow-nan-bug) ▾ Traduire cette page

10 nov. 2015 - I was looking at the Tensorflow MNIST example for beginners and found that in this part: ... here: [stackoverflow.com/questions/33712178/tensorflow-nan-bug](http://stackoverflow.com/questions/33712178/tensorflow-nan-bug) ...  
`cross_entropy = -tf.reduce_sum(y_*tf.log(y))` `cross_entropy = tf.`

## **Practical issues of cross entropy:**

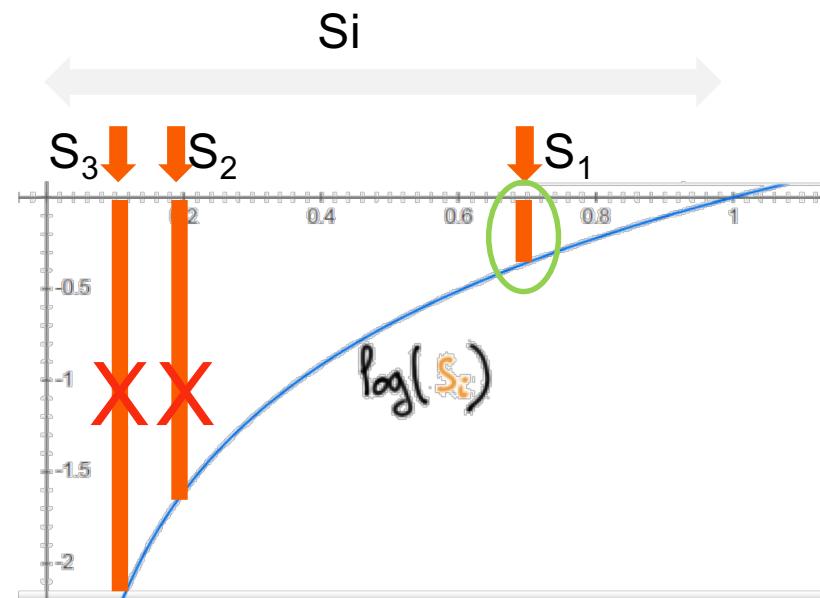
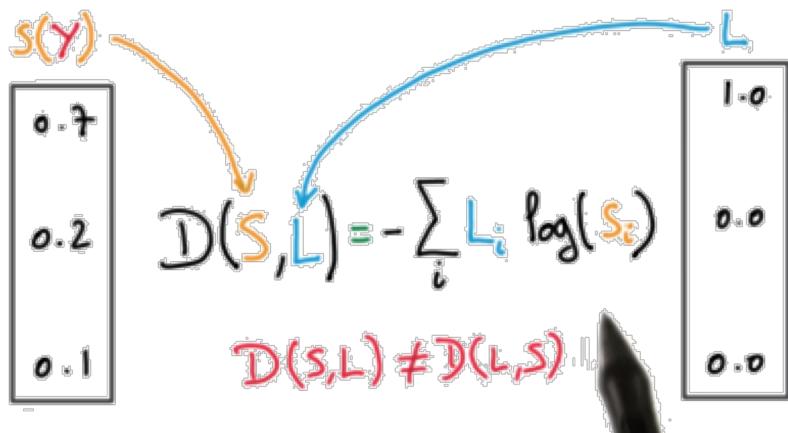
```
cross_entropy = -tf.reduce_sum(y_*tf.log(y_conv))
```

Replace with:

```
cross_entropy = -tf.reduce_sum(y_*tf.log(tf.clip_by_value(y_conv,1e-10,1.0)))
```

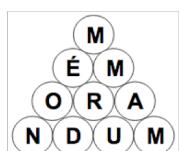
$$\frac{3a(y_1 + z_2)^2 + (y_3 + z_4 + A(x_1 + z_5))^2}{39}$$

## CROSS-ENTROPY



Seule la probabilité calculée de la bonne classe est prise en compte (le coefficient  $L$  des autres classes est à 0)  
Pour la bonne classe l'erreur est calculée comme  $-\log(S_1)$

$$D(S, L) = -\log(S_1)$$



$$\frac{3a(y+z)^2 + 3y + 4A(x+z)}{39}$$

## Test de progression significative

3000

EXAMPLES

80% → 81%

80% → 80.5%

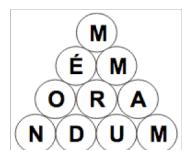
80% → 80.1%

1% \* 3000 = 30 OK !

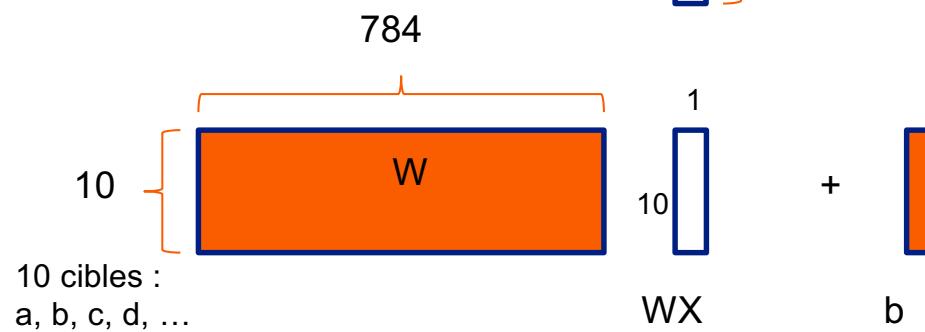
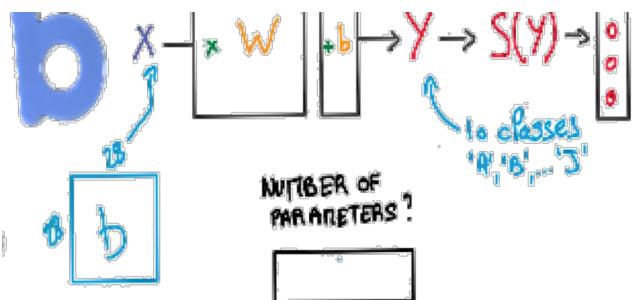
0,5% \* 3000 = 15 KO !

0,1% \* 3000 = 3 KO !

Une progression portant sur plus de 30 unités considérée comme significative  
 → La taille de son test set définit le niveau de précision de réglage du modèle que vous pouvez chercher

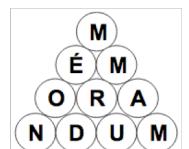


$$3a(y+z)^2 + 3y^2 + 4(x+z)^2 + \dots = 39$$

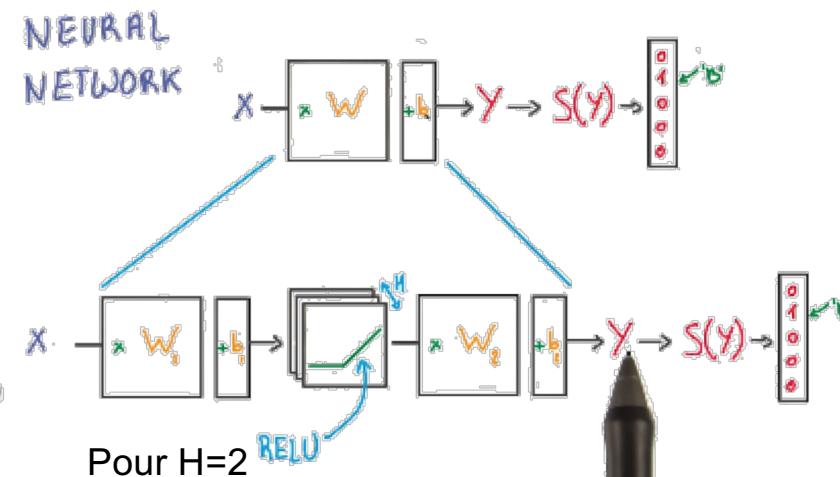


Vecteur de  
 $28 \times 28 = 784$

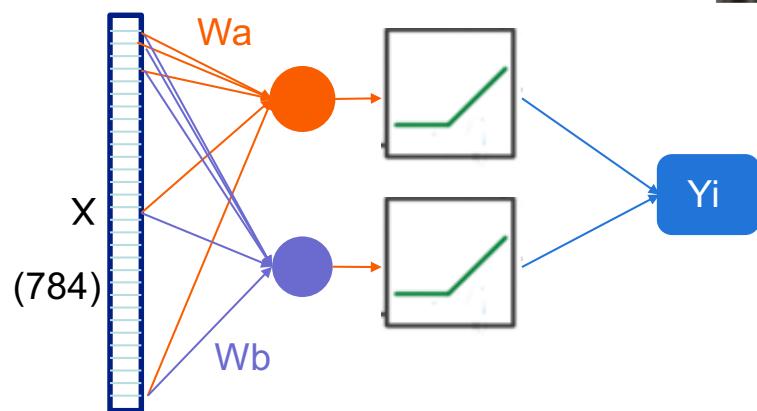
Nombre de paramètres :  
 $784 \times 10$  (pour  $w$ ) + 10 (pour  $b$ ) : 7850



$$\begin{aligned}
 & 3a(y+z)^2 + (y+z) + 4A(x+z) \\
 & \frac{a^2}{39} (y+A)^3 + \frac{2}{3} A^2 (x+z)
 \end{aligned}$$

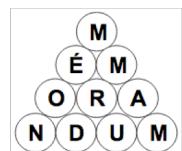


Pour chaque cible

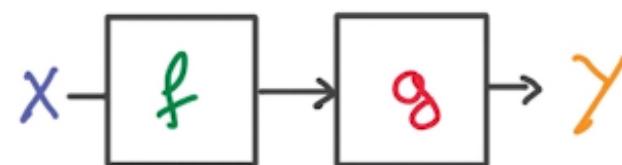


Il y a donc  
784\*10\*2 paramètres  
W pour la première  
couche

Il y a  
2\*10 paramètres W  
pour la 2è couche



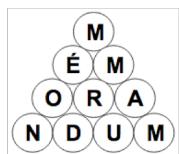
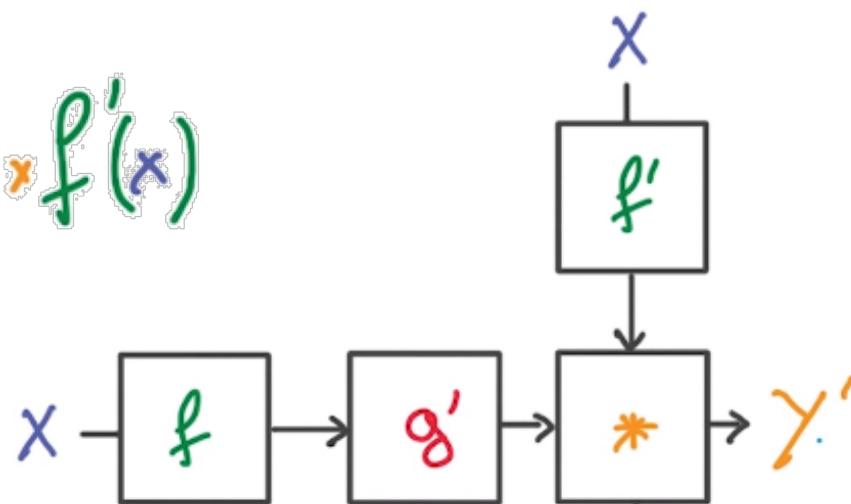
$$\frac{3a(y+z)^2 + (3y+4z+4A(x+z))}{39}$$



$$[g(f(x))]' = g'(f(x)) \cdot f'(x)$$



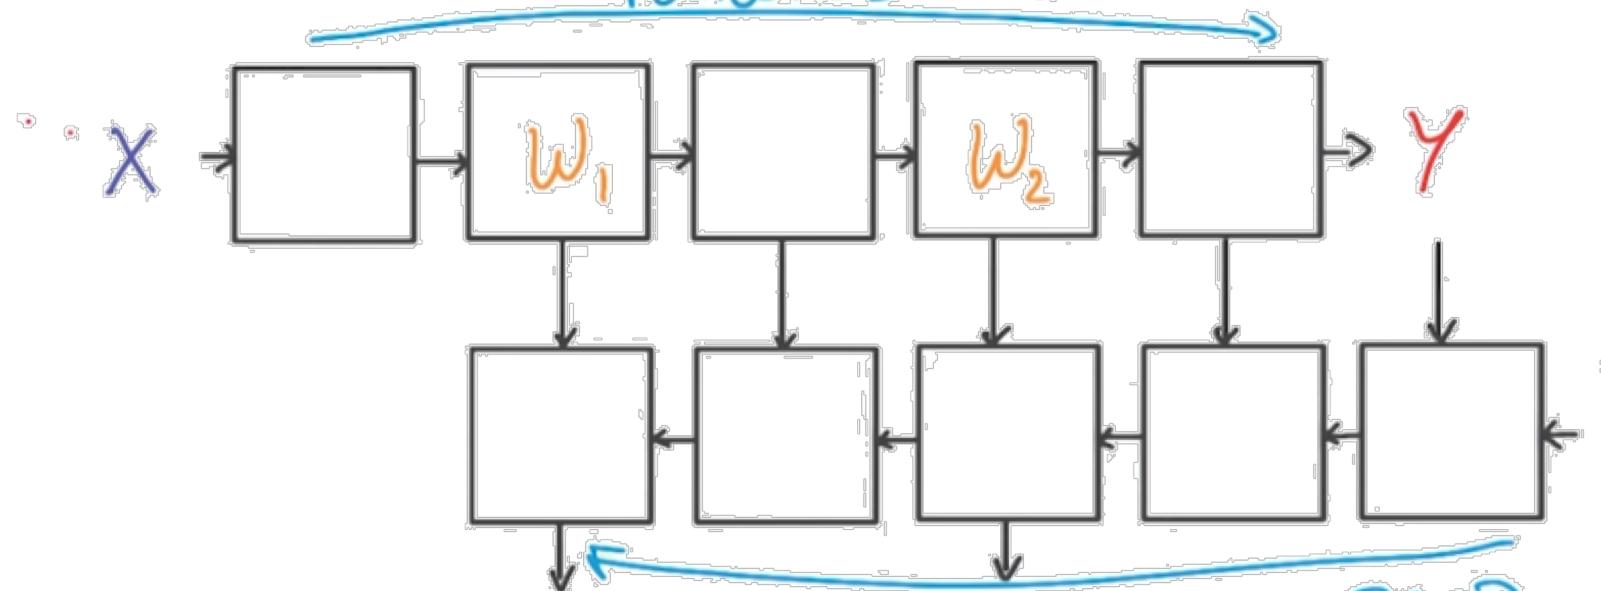
$wx$



$$\begin{aligned}
 & 3a(y+z)^2 + (y+z) + \\
 & \frac{a^2(z+1)}{39} (y+A)^{13} + \frac{2}{3} A^2(x+ \\
 & \dots
 \end{aligned}$$

## BACK - PROPAGATION

FORWARD PROP

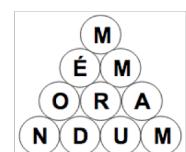


$\Delta w_1$

$$w_1 \leftarrow w_1 - \alpha \Delta w_1$$

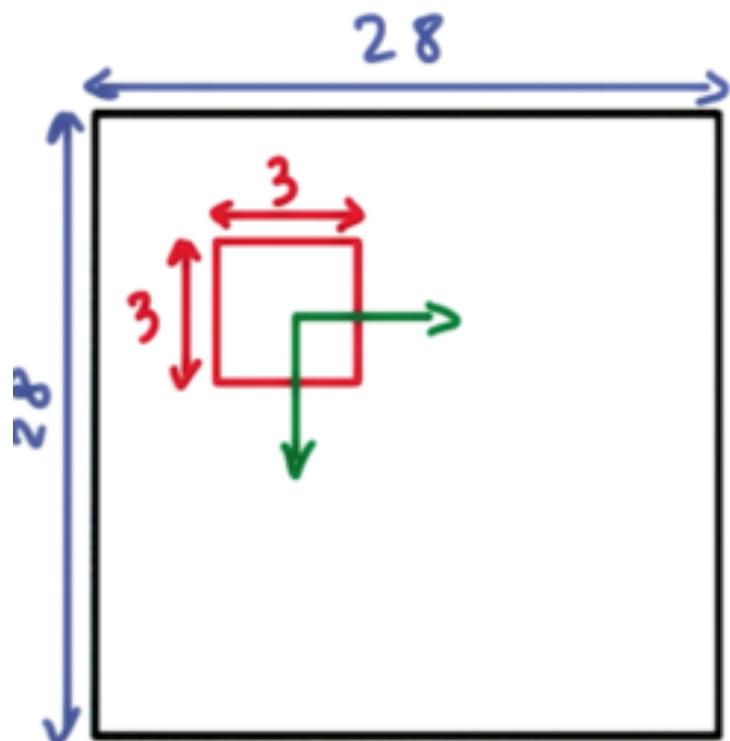
$\Delta w_2$

$$w_2 \leftarrow w_2 - \alpha \Delta w_2$$



$$\frac{3a(y+1)^2 + (3y + 4 + 4A(x+1))}{39} - \frac{a^2(3-1)(y+A)}{3} + \frac{2}{3}a^2(A)^2(x+1)$$

## STRIDES, DEPTH & PADDING



INPUT DEPTH = 3  
OUTPUT DEPTH = 8

OUTPUT				
PADDING	STRIDE	WIDTH	HEIGHT	DEPTH
'SAME'	1	28	28	8
'VALID'	1	26	26	8
'VALID'	2	13	13	8

